

# Aplikacja do generowania animacji na podstawie opisów tekstowych

Ryszard Żmija    Maciej Grzybacz    Michał Proć

**Opiekun pracy:** dr hab. inż. Rafał Dreżewski, prof. AGH

# Plan prezentacji

- 1 Wprowadzenie
- 2 Architektura systemu
- 3 Demonstracja
- 4 Wyzwania i ograniczenia
- 5 Podsumowanie

# Cel i zakres pracy

## Cel pracy

Zaprojektowanie i implementacja aplikacji webowej oraz autoskalowalnego, rozproszonego systemu do generacji **wideo z opisów tekstowych**, wykorzystującego modele dyfuzyjne rozszerzone o mechanizmy zapewniające **spójność czasową** sekwencji klatek.

## Zakres realizacji

- Pipeline generacji wideo oparty na **AnimateDiff** i **Stable Diffusion**
- Interfejs webowy do interakcji z systemem
- Skalowalna architektura z wykorzystaniem **Ray Framework**
- Integracja z bazami danych i storage'em obiekowym

# Problem generacji wideo z tekstu

Generacja wideo z opisów tekstowych wymaga rozwiązania trzech fundamentalnych problemów:

- **Spójność czasowa** – zachowanie ciągłości obiektów i sceny między kolejnymi klatkami
- **Semantyczna zgodność** – wierne odwzorowanie treści opisu w generowanym materiale
- **Złożoność obliczeniowa oraz pamięciowa** – efektywne przetwarzanie danych wielowymiarowych (przestrzeń + czas)



# Podejścia do generacji wideo

## End-to-end

- Modele trenowane od podstaw na danych wideo
- Przykłady: Sora, Veo, CogVideoX
- Wysoka jakość, duże wymagania sprzętowe
- Zamknięte lub bardzo kosztowne obliczeniowo

## Modularne

- Rozszerzenia modeli text-to-image o moduły ruchu
- Przykład: AnimateDiff
- Niższy koszt obliczeniowy
- Open-source, elastyczność

*W pracy wykorzystano podejście modularne.*

# Parametry AnimateDiff

## Treść i kontrola

- **prompt** – opis treści wideo
- **negative\_prompt** – elementy do unikania


## Parametry wideo

- **video\_width**, **video\_height** – wymiary w pikselach
- **video\_length** – długość wideo w sekundach
- **fps** – liczba klatek na sekundę


## Jakość i modele

- **inference\_steps** – liczba kroków dyfuzji (jakość vs. szybkość)
- **guidance\_scale** – siła zgodności z promptem
- **base\_model** – wybór modelu bazowego (SD1.5, EpicRealism, etc.)

# Architektura wysokopoziomowa



# Pipeline generowania wideo



# Przykład wygenerowanego wideo

*Prompt: "A corgi walking on the street, cinematic"*

# Napotkane wyzwania

## Zarządzanie pamięcią

- **Zimny start** – ładowanie wag ( $\sim 8\text{GB}$ ) na GPU przy każdym uruchomieniu aktora Ray
- **Serializacja w Ray** – transfer tensorów GPU $\rightarrow$ CPU $\rightarrow$ GPU przez object store wymaga dodatkowych kopii
- **Zużycie VRAM** – AnimateDiff wymaga utrzymania wszystkich klatek w pamięci GPU jednocześnie

## Spójność czasowa

- **Temporal flickering** – niezależne próbkowanie szumu dla każdej klatki powoduje niestabilność detali
- **Deformacje obiektów** – brak modelowania 3D prowadzi do niespójności kształtów między klatkami
- **Artefakty upscalingu** – Real-ESRGAN przetwarza klatki niezależnie, generując różne detale

# Zrealizowane cele

## Co zostało zrealizowane:

- Funkcjonalny pipeline generacji wideo (text-to-video) oparty na AnimateDiff
- Aplikacja webowa umożliwiająca interakcję z systemem
- Skalowalna architektura z wykorzystaniem Ray Serve
- Integracja modułów: generacja klatek, interpolacja czasowa (FILM), super-resolution (Real-ESRGAN)
- System persystencji danych (PostgreSQL + MinIO)

**Wykorzystane technologie:** Stable Diffusion, AnimateDiff, FILM, Real-ESRGAN, Ray Framework, FastAPI, Next.js

# Wnioski

1. Podejście modularne (AnimateDiff + interpolacja + upscaling) pozwala na generację wideo przy ograniczonych zasobach, ale wymaga łączenia wielu niezależnych komponentów.
2. Modele end-to-end (Sora, Veo) osiągają lepszą spójność czasową, ponieważ generują wideo w jednym przejściu z natywną temporal attention – architektura uczy się zależności czasowych, zamiast je aproksymować post-hoc.
3. Kluczowym ograniczeniem obecnych modeli text-to-video pozostaje brak świadomości 3D – obiekty mogą się deformować, ponieważ model operuje na projekcjach 2D bez reprezentacji geometrii sceny.



# Perspektywy rozwoju

- Przeniesienie systemu do chmury (AWS/GCP) z dynamicznym skalowaniem GPU w zależności od obciążenia
- Rozbudowa aplikacji o funkcje społecznościowe – publiczna galeria wygenerowanych wideo, udostępnianie promptów między użytkownikami
- Integracja z nowymi modelami open-source, takimi jak Wan2.1 od Alibaba, które oferują generację end-to-end z natywną spójnością czasową
- Wsparcie dla zaawansowanych trybów generacji – kontrola trajektorii kamery, edycja wybranych fragmentów wideo, animacja na podstawie obrazu referencyjnego

# Bibliografia I

## Modele dyfuzyjne – podstawy:

- J. Ho, A. Jain, P. Abbeel, **Denoising Diffusion Probabilistic Models**, NeurIPS 2020. *arXiv:2006.11239*
- R. Rombach et al., **High-Resolution Image Synthesis with Latent Diffusion Models**, CVPR 2022. *arXiv:2112.10752*
- W. Peebles, S. Xie, **Scalable Diffusion Models with Transformers**, ICCV 2023. *arXiv:2212.09748*

## Generacja wideo:

- Y. Guo et al., **AnimateDiff: Animate Your Personalized Text-to-Image Diffusion Models**, ICLR 2024. *arXiv:2307.04725*
- A. Blattmann et al., **Align your Latents: High-Resolution Video Synthesis with Latent Diffusion Models**, CVPR 2023. *arXiv:2304.08818*
- Team Wan, **Wan: Open and Advanced Large-Scale Video Generative Models**, 2025. *arXiv:2503.20314*
- OpenAI, **Video generation models as world simulators** (Sora Technical Report), 2024.

# Bibliografia II

## Przetwarzanie wideo:

- F. Reda et al., **FILM: Frame Interpolation for Large Motion**, ECCV 2022. *arXiv:2202.04901*
- X. Wang et al., **Real-ESRGAN: Training Real-World Blind Super-Resolution with Pure Synthetic Data**, ICCVW 2021. *arXiv:2107.10833*

## Systemy rozproszone:

- P. Moritz et al., **Ray: A Distributed Framework for Emerging AI Applications**, OSDI 2018. *arXiv:1712.05889*

# Dziękujemy za uwagę



Maciej Grzybacz



Michał Proć